

Clasificación de enfermedades en hojas de plantas mediante transfer learning: comparación de arquitecturas livianas y explicabilidad con Grad-CAM

BETTIG, Santiago Federico
CEIA - FIUBA
Universidad de Buenos Aires
Buenos Aires, Argentina
santiagobettig@gmail.com

RUBIOLO, Pedro Ignacio
CEIA - FIUBA
Universidad de Buenos Aires
Buenos Aires, Argentina
rubiolopedroignacio@gmail.com

DIEGUEZ, Manuel
CEIA - FIUBA
Universidad de Buenos Aires
Buenos Aires, Argentina
manueldieguetz@gmail.com

TOLOTTO, Lourdes
CEIA - FIUBA
Universidad de Buenos Aires
Buenos Aires, Argentina
tolottolourdes2309@gmail.com

Resumen—[PENDIENTE: Resumen (150–250 palabras). Se redacta al final, cuando estén todos los resultados.]

Palabras clave—clasificación de imágenes, enfermedades de plantas, transfer learning, PlantVillage, EfficientNet, MobileNetV3, Grad-CAM

I. INTRODUCCIÓN

Las plagas y enfermedades de los cultivos son una de las principales amenazas para la seguridad alimentaria. Una evaluación global sobre cinco cultivos básicos estimó que las pérdidas de rendimiento atribuibles a patógenos y plagas alcanzan, en el caso de la papa, un 17,2 % en promedio (8,1–21,0 % según la región), y que las pérdidas más altas se concentran en regiones con déficit de alimentos [1]. El manejo de estas enfermedades depende de un diagnóstico temprano, que todavía se apoya mayormente en la inspección visual realizada por especialistas: un recurso escaso y costoso, sobre todo para productores pequeños y alejados de los centros técnicos.

El aprendizaje profundo y la masificación de los teléfonos inteligentes abrieron la posibilidad de automatizar ese diagnóstico a partir de una fotografía de la hoja. El dataset PlantVillage [2] fue el punto de partida de esta línea: sobre 54 306 imágenes de 14 especies, una red convolucional alcanzó un 99,35 % de accuracy en un conjunto de test separado [3]. Sin embargo, el mismo trabajo reportó que el accuracy caía al 31,4 % sobre imágenes obtenidas de otras fuentes. Estudios posteriores mostraron que PlantVillage contiene sesgos de captura que un modelo puede explotar (por ejemplo, un clasificador entrenado con solo 8 píxeles del fondo alcanza un 49 % de accuracy [4]) y propusieron conjuntos de imágenes tomadas

en condiciones reales, como PlantDoc [5]. En consecuencia, un accuracy cercano al 100 % en PlantVillage no garantiza por sí solo un modelo útil en el campo, y su evaluación debe complementarse con controles de fuga de datos, explicabilidad y pruebas fuera de la distribución de entrenamiento.

Un caso real que ilustra tanto el potencial como esta brecha es PlantVillage Nuru, una aplicación móvil que ejecuta sin conexión un modelo de detección de síntomas foliares en mandioca [6]. En una evaluación de campo en Tanzania, Nuru alcanzó un 65 % de accuracy en el diagnóstico de enfermedades virales, por encima de los extensionistas agrícolas (40–58 %) y de los productores (18–31 %), y llegó al 74–88 % cuando el diagnóstico combinaba seis hojas por planta [7]. Estos resultados muestran que un modelo liviano ejecutado en el teléfono puede aportar valor real, pero también que el desempeño en el campo es muy inferior al que se obtiene en el laboratorio.

En este trabajo desarrollamos un prototipo de clasificación de enfermedades foliares en tres cultivos de importancia hortícola (pimiento, papa y tomate), con 15 clases que incluyen hojas sanas y enfermas de PlantVillage. Partimos de modelos preentrenados en ImageNet y priorizamos arquitecturas livianas (MobileNetV3 [8] y EfficientNet-B0 [9]), compatibles con una inferencia en CPU o en dispositivos móviles. Las contribuciones principales son:

- un protocolo de partición estratificada y agrupada por imágenes casi duplicadas, que reduce la fuga de datos entre entrenamiento y test;
- una comparación sistemática entre *linear probe* y *fine-tuning* parcial de distintos backbones, con y sin data augmentation;

- un análisis cuantitativo de explicabilidad con Grad-CAM [10], que mide qué fracción de la atención del modelo recae sobre la hoja y no sobre el fondo;
- una evaluación de robustez ante perturbaciones de la imagen y sobre datos externos a PlantVillage, junto con la medición del costo de inferencia en CPU.

El resto del trabajo se organiza de la siguiente manera: la Sección II describe los datos, la partición, las arquitecturas y el protocolo experimental; la Sección III presenta y analiza los resultados; y la Sección IV resume las conclusiones y las líneas de trabajo futuro.

II. METODOLOGÍA, DISEÑO Y DESARROLLO

II-A. Dataset

Utilizamos el subconjunto de PlantVillage [2] correspondiente a pimiento, papa y tomate: 20 638 imágenes RGB de 256×256 píxeles distribuidas en 15 clases (12 enfermedades y 3 clases de hoja sana). Las imágenes fueron tomadas en condiciones de laboratorio, con una única hoja centrada sobre un fondo uniforme. El dataset está desbalanceado (Fig. 1a): la clase mayoritaria (virus del rizado amarillo del tomate, TYLCV) tiene 3 208 imágenes y la minoritaria (papa sana) 152, una relación de 21:1. Las hojas sanas representan el 15,6 % del total. Por este desbalance adoptamos el macro-F1 como métrica principal.


II-B. Partición de datos y control de fuga

PlantVillage incluye varias fotografías de una misma hoja, por lo que una partición aleatoria puede ubicar imágenes casi idénticas en entrenamiento y en test e inflar las métricas. Para detectarlas calculamos un hash criptográfico (MD5) de cada archivo y un hash perceptual (dHash de 64 bits). Encontramos 28 imágenes en 14 grupos de duplicados, todos con etiquetas consistentes. Luego realizamos una partición estratificada por clase y *agrupada* por dHash (StratifiedGroupKFold, semilla fija), de modo que las imágenes de un mismo grupo caen siempre en el mismo subconjunto. El resultado es una partición 71,4/14,3/14,3 % (14 740 imágenes de entrenamiento, 2 949 de validación y 2 949 de test), sin grupos compartidos entre subconjuntos. Esta partición se versiona en el repositorio y es la misma para todos los experimentos. Como el dHash no es invariante a rotaciones, este control no elimina la fuga entre fotografías rotadas de una misma hoja; lo consideramos una limitación del estudio.

II-C. Preprocesamiento y data augmentation

Las imágenes se normalizan con la media y el desvío de ImageNet, que son los usados para preentrenar los backbones. Validación y test usan siempre un preprocesamiento determinístico (solo redimensionado). El data augmentation se aplica únicamente en entrenamiento y combina recortes aleatorios (escala 0,6 - 1,0), volteos horizontales y verticales, rotaciones de hasta $\pm 30^\circ$ ($p = 0,5$), variaciones moderadas de color (brillo y contraste ± 30 %, saturación ± 20 %, tono $\pm 0,03$) y desenfoque gaussiano ($p = 0,2$) (Fig. 1b). Las hojas no tienen una orientación canónica, por lo que las transformaciones

(a) Imágenes por clase



(b) Hoja original (recuadro azul) y siete muestras aumentadas



Figura 1. (a) Cantidad de imágenes por clase en el subconjunto de PlantVillage utilizado. (b) Una hoja de entrenamiento (tizón temprano del tomate) y siete muestras generadas por el pipeline de data augmentation usado en el fine-tuning (160×160).

geométricas son válidas. En cambio, las variaciones de color se limitaron porque el color es en sí mismo una señal diagnóstica (clorosis, necrosis).

II-D. Arquitecturas y estrategia de transferencia

Elegimos backbones preentrenados en ImageNet con distintos compromisos entre costo y capacidad: MobileNetV3-Small y MobileNetV3-Large [8], EfficientNet-B0 [9] y, como referencia sin optimización para dispositivos móviles, ResNet18. Como el entrenamiento se realizó íntegramente en CPU, seguimos una estrategia en dos etapas:

1. **Linear probe:** con el backbone congelado, extraemos una única vez los embeddings de todas las imágenes a 224×224 y entrenamos sobre ellos una capa lineal. Esta etapa, de pocos segundos por modelo, mide la calidad de las representaciones de ImageNet para este dominio y permite comparar las cuatro arquitecturas a bajo costo. También evaluamos una entropía cruzada ponderada por la frecuencia inversa de cada clase.
2. **Fine-tuning parcial:** para las dos arquitecturas con mayor macro-F1 en validación en la etapa anterior (EfficientNet-B0 y MobileNetV3-Small, esta última además la de menor costo), reemplazamos el clasificador y reentrenamos las últimas etapas del backbone (6 bloques en MobileNetV3-Small y 3 en EfficientNet-B0,

Tabla I
CONFIGURACIÓN DE ENTRENAMIENTO

	Linear probe	Fine-tuning
Resolución de entrada	224 × 224	160 × 160
Capas entrenadas	capa lineal	últimas etapas + cabeza
Optimizador	AdamW	AdamW
Learning rate ^a	3×10^{-3}	$10^{-3} / 3 \times 10^{-4}$
Weight decay	10^{-3}	10^{-4}
Scheduler	coseno	coseno
Batch / épocas	256 / 60	32 / 8
Pérdida	CE y CE ponderada	CE
Selección del modelo	máximo macro-F1 en validación	

^aEn fine-tuning: cabeza / backbone.

con 1,39M y 3,17M parámetros entrenables, respectivamente). Las BatchNorm de las etapas congeladas se mantienen en modo evaluación para no alterar sus estadísticas. Cada arquitectura se entrena con y sin data augmentation, en un diseño 2×2 en el que todo lo demás (semilla, partición, resolución, optimizador y número de épocas) permanece fijo.

II-E. Protocolo de entrenamiento y métricas

La Tabla I resume los hiperparámetros de ambas etapas. Para reducir el costo en CPU, el fine-tuning se realiza a 160×160 píxeles. En las dos etapas, la mejor época se elige por macro-F1 en validación, y el conjunto de test se evalúa una única vez con el modelo seleccionado. Reportamos accuracy, balanced accuracy y macro-F1, además del F1 por clase y la matriz de confusión para el análisis de errores. Como métricas de costo registramos el tiempo de entrenamiento, el número de parámetros y la latencia de inferencia en CPU.

II-F. Explicabilidad con Grad-CAM

Para auditar en qué regiones de la imagen se basa el mejor modelo aplicamos Grad-CAM [10] sobre la última capa convolucional del backbone (un mapa de 5×5 a la resolución de entrada), calculado para la clase predicha. Además del análisis visual, cuantificamos la atención del modelo sobre todo el conjunto de test. Para cada imagen segmentamos la hoja con un umbral de Otsu sobre el canal de saturación (el fondo de laboratorio es poco saturado), seguido de limpieza morfológica. Con la máscara M resultante y el mapa Grad-CAM normalizado L calculamos la fracción de la activación que recae sobre la hoja:

$$E_{\text{hoja}} = \frac{\sum_{i,j} L_{ij} M_{ij}}{\sum_{i,j} L_{ij}}, \quad (1)$$

Como un mapa uniforme obtendría un valor igual al área relativa de la hoja, también reportamos el cociente entre E_{hoja} y esa área (mayor que 1 si la atención se concentra en la hoja más de lo esperable por azar). Por último, aplicamos el *pointing game*, que mide el porcentaje de imágenes cuyo máximo de activación cae dentro de la hoja. Estas métricas permiten detectar si el modelo explota el fondo, un sesgo conocido de PlantVillage [4], en lugar de los síntomas.

II-G. Evaluación de robustez y con datos externos

[PENDIENTE: Perturbaciones aplicadas al test (tipos y niveles), dataset externo utilizado, mapeo de clases y protocolo de evaluación.]

III. RESULTADOS EXPERIMENTALES Y ANÁLISIS

III-A. Comparación de backbones (linear probe)

III-B. Fine-tuning con y sin data augmentation

III-C. Análisis por clase y de errores

III-D. Explicabilidad (Grad-CAM)

III-E. Robustez ante perturbaciones

III-F. Evaluación con datos externos

III-G. Costo computacional

IV. CONCLUSIONES

REFERENCIAS

- [1] S. Savary, L. Willocquet, S. J. Pethybridge, P. Esker, N. McRoberts, and A. Nelson, "The global burden of pathogens and pests on major food crops," *Nature Ecology & Evolution*, vol. 3, no. 3, pp. 430–439, 2019.
- [2] D. P. Hughes and M. Salathé, "An open access repository of images on plant health to enable the development of mobile disease diagnostics," arXiv:1511.08060, 2015. [Online]. Available: <https://arxiv.org/abs/1511.08060>
- [3] S. P. Mohanty, D. P. Hughes, and M. Salathé, "Using deep learning for image-based plant disease detection," *Frontiers in Plant Science*, vol. 7, p. 1419, 2016.
- [4] M. A. Noyan, "Uncovering bias in the PlantVillage dataset," arXiv:2206.04374, 2022. [Online]. Available: <https://arxiv.org/abs/2206.04374>
- [5] D. Singh, N. Jain, P. Jain, P. Kayal, S. Kumawat, and N. Batra, "PlantDoc: A dataset for visual plant disease detection," in *Proc. 7th ACM IKDD CoDS and 25th COMAD*, 2020, pp. 249–253.
- [6] A. Ramcharan, P. McCloskey, K. Baranowski, N. Mbilinyi, L. Mrisho, M. Ndalawha, J. Legg, and D. P. Hughes, "A mobile-based deep learning model for cassava disease diagnosis," *Frontiers in Plant Science*, vol. 10, p. 272, 2019.
- [7] L. M. Mrisho, N. A. Mbilinyi, M. Ndalawha *et al.*, "Accuracy of a smartphone-based object detection model, PlantVillage Nuru, in identifying the foliar symptoms of the viral diseases of cassava—CMD and CBSD," *Frontiers in Plant Science*, vol. 11, p. 590889, 2020.
- [8] A. Howard, M. Sandler, G. Chu, L.-C. Chen, B. Chen, M. Tan, W. Wang, Y. Zhu, R. Pang, V. Vasudevan, Q. V. Le, and H. Adam, "Searching for MobileNetV3," in *Proc. IEEE/CVF Int. Conf. Computer Vision (ICCV)*, 2019, pp. 1314–1324.
- [9] M. Tan and Q. V. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in *Proc. 36th Int. Conf. Machine Learning (ICML)*, ser. PMLR, vol. 97, 2019, pp. 6105–6114.
- [10] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, "Grad-CAM: Visual explanations from deep networks via gradient-based localization," in *Proc. IEEE Int. Conf. Computer Vision (ICCV)*, 2017, pp. 618–626.