

Clasificación de enfermedades en hojas de plantas mediante transfer learning: comparación de arquitecturas livianas y explicabilidad con Grad-CAM

BETTIG, Santiago Federico
CEIA - FIUBA
Universidad de Buenos Aires
Buenos Aires, Argentina
santiagofbetti@gmail.com

RUBIOLO, Pedro Ignacio
CEIA - FIUBA
Universidad de Buenos Aires
Buenos Aires, Argentina
rubiolopedroignacio@gmail.com

DIEGUEZ, Manuel
CEIA - FIUBA
Universidad de Buenos Aires
Buenos Aires, Argentina
manueldieguetz@gmail.com

TOLOTTO, Lourdes
CEIA - FIUBA
Universidad de Buenos Aires
Buenos Aires, Argentina
tolottolourdes2309@gmail.com

Resumen—El diagnóstico temprano de enfermedades en los cultivos depende de la inspección visual de especialistas, un recurso escaso para muchos productores. En este trabajo desarrollamos un prototipo de clasificación de 15 clases de hojas sanas y enfermas de pimiento, papa y tomate del dataset PlantVillage, basado en arquitecturas livianas preentrenadas en ImageNet y entrenado íntegramente en CPU. Para evitar la fuga de datos, particionamos el dataset de forma estratificada y agrupada por imágenes casi duplicadas. Comparamos cuatro backbones mediante linear probe y aplicamos fine-tuning parcial a MobileNetV3-Small y EfficientNet-B0, con y sin data augmentation. EfficientNet-B0 con augmentation alcanza un macro-F1 de 0,993 en test, con una latencia de 17,5 ms por imagen en CPU. El augmentation no modifica el desempeño en el test original, pero es decisivo ante perturbaciones: con desenfoque, el macro-F1 cae 0,23 sin augmentation y solo 0,013 con él. Un análisis cuantitativo con Grad-CAM muestra que el 65,7 % de la activación recae sobre la hoja, que ocupa el 40,2 % de la imagen, y que los errores se deben a síntomas ambiguos más que a una atención desviada hacia el fondo. Sin embargo, sobre imágenes de campo del dataset PlantDoc el accuracy cae al 36,7 %. Estos resultados indican que un desempeño cercano al 100 % en PlantVillage no garantiza la utilidad del modelo en condiciones reales.

Palabras clave—clasificación de imágenes, enfermedades de plantas, transfer learning, PlantVillage, EfficientNet, MobileNetV3, Grad-CAM

I. INTRODUCCIÓN

Las plagas y enfermedades de los cultivos son una de las principales amenazas para la seguridad alimentaria. Una evaluación global sobre cinco cultivos básicos estimó que las pérdidas de rendimiento atribuibles a patógenos y plagas alcanzan, en el caso de la papa, un 17,2 % en promedio (8,1–21,0 % según la región), y que las pérdidas más altas se concentran en regiones con déficit de alimentos [1]. El

manejo de estas enfermedades depende de un diagnóstico temprano, que todavía se apoya mayormente en la inspección visual realizada por especialistas: un recurso escaso y costoso, sobre todo para productores pequeños y alejados de los centros técnicos.

El aprendizaje profundo y la masificación de los teléfonos inteligentes abrieron la posibilidad de automatizar ese diagnóstico a partir de una fotografía de la hoja. El dataset PlantVillage [2] fue el punto de partida de esta línea: sobre 54 306 imágenes de 14 especies, una red convolucional alcanzó un 99,35 % de accuracy en un conjunto de test separado [3]. Sin embargo, el mismo trabajo reportó que el accuracy caía al 31,4 % sobre imágenes obtenidas de otras fuentes. Estudios posteriores mostraron que PlantVillage contiene sesgos de captura que un modelo puede explotar (por ejemplo, un clasificador entrenado con solo 8 píxeles del fondo alcanza un 49 % de accuracy [4]) y propusieron conjuntos de imágenes tomadas en condiciones reales, como PlantDoc [5]. En consecuencia, un accuracy cercano al 100 % en PlantVillage no garantiza por sí solo un modelo útil en el campo, y su evaluación debe complementarse con controles de fuga de datos, explicabilidad y pruebas fuera de la distribución de entrenamiento.

Un caso real que ilustra tanto el potencial como esta brecha es PlantVillage Nuru, una aplicación móvil que ejecuta sin conexión un modelo de detección de síntomas foliares en mandioca [6]. En una evaluación de campo en Tanzania, Nuru alcanzó un 65 % de accuracy en el diagnóstico de enfermedades virales, por encima de los extensionistas agrícolas (40–58 %) y de los productores (18–31 %), y llegó al 74–88 % cuando el diagnóstico combinaba seis hojas por planta [7]. Estos resultados muestran que un modelo liviano ejecutado

en el teléfono puede aportar valor real, pero también que el desempeño en el campo es muy inferior al que se obtiene en el laboratorio.

En este trabajo desarrollamos un prototipo de clasificación de enfermedades foliares en tres cultivos de importancia hortícola (pimiento, papa y tomate), con 15 clases que incluyen hojas sanas y enfermas de PlantVillage. Partimos de modelos preentrenados en ImageNet y priorizamos arquitecturas livianas (MobileNetV3 [8] y EfficientNet-B0 [9]), compatibles con una inferencia en CPU o en dispositivos móviles. Las contribuciones principales son:

- un protocolo de partición estratificada y agrupada por imágenes casi duplicadas, que reduce la fuga de datos entre entrenamiento y test;
- una comparación sistemática entre *linear probe* y *fine-tuning* parcial de distintos backbones, con y sin data augmentation;
- un análisis cuantitativo de explicabilidad con Grad-CAM [10], que mide qué fracción de la atención del modelo recae sobre la hoja y no sobre el fondo;
- una evaluación de robustez ante perturbaciones de la imagen y sobre datos externos a PlantVillage, junto con la medición del costo de inferencia en CPU.

El resto del trabajo se organiza de la siguiente manera: la Sección II describe los datos, la partición, las arquitecturas y el protocolo experimental; la Sección III presenta y analiza los resultados; y la Sección IV resume las conclusiones y las líneas de trabajo futuro.

II. METODOLOGÍA, DISEÑO Y DESARROLLO


II-A. Dataset

Utilizamos el subconjunto de PlantVillage [2] correspondiente a pimiento, papa y tomate: 20 638 imágenes RGB de 256×256 píxeles distribuidas en 15 clases (12 enfermedades y 3 clases de hoja sana). Las imágenes fueron tomadas en condiciones de laboratorio, con una única hoja centrada sobre un fondo uniforme. El dataset está desbalanceado (Fig. 1a): la clase mayoritaria (virus del rizado amarillo del tomate, TYLCV) tiene 3 208 imágenes y la minoritaria (papa sana) 152, una relación de 21:1. Las hojas sanas representan el 15,6 % del total. Por este desbalance adoptamos el macro-F1 como métrica principal.

II-B. Partición de datos y control de fuga

PlantVillage incluye varias fotografías de una misma hoja, por lo que una partición aleatoria puede ubicar imágenes casi idénticas en entrenamiento y en test e inflar las métricas. Para detectarlas calculamos un hash criptográfico (MD5) de cada archivo y un hash perceptual (dHash de 64 bits). Encontramos 28 imágenes en 14 grupos de duplicados, todos con etiquetas consistentes. Luego realizamos una partición estratificada por clase y *agrupada* por dHash (StratifiedGroupKFold, semilla fija), de modo que las imágenes de un mismo grupo caen siempre en el mismo subconjunto. El resultado es una partición 71,4/14,3/14,3 % (14 740 imágenes de entrenamiento, 2 949 de validación y 2 949 de test), sin grupos compartidos

(a) Imágenes por clase



(b) Hoja original (recuadro azul) y siete muestras aumentadas



Figura 1. (a) Cantidad de imágenes por clase en el subconjunto de PlantVillage utilizado. (b) Una hoja de entrenamiento (tizón temprano del tomate) y siete muestras generadas por el pipeline de data augmentation usado en el fine-tuning (160×160).

entre subconjuntos. Esta partición se versiona en el repositorio y es la misma para todos los experimentos. Como el dHash no es invariante a rotaciones, este control no elimina la fuga entre fotografías rotadas de una misma hoja; lo consideramos una limitación del estudio.

II-C. Preprocesamiento y data augmentation

Las imágenes se normalizan con la media y el desvío de ImageNet, que son los usados para preentrenar los backbones. Validación y test usan siempre un preprocesamiento determinístico (solo redimensionado). El data augmentation se aplica únicamente en entrenamiento y combina recortes aleatorios (escala 0,6 - 1,0), volteos horizontales y verticales, rotaciones de hasta $\pm 30^\circ$ ($p = 0,5$), variaciones moderadas de color (brillo y contraste $\pm 30\%$, saturación $\pm 20\%$, tono $\pm 0,03$) y desenfoque gaussiano ($p = 0,2$) (Fig. 1b). Las hojas no tienen una orientación canónica, por lo que las transformaciones geométricas son válidas. En cambio, las variaciones de color se limitaron porque el color es en sí mismo una señal diagnóstica (clorosis, necrosis).

II-D. Arquitecturas y estrategia de transferencia

Elegimos backbones preentrenados en ImageNet con distintos compromisos entre costo y capacidad: MobileNetV3-Small y MobileNetV3-Large [8], EfficientNet-B0 [9] y, como

Tabla I
CONFIGURACIÓN DE ENTRENAMIENTO

	Linear probe	Fine-tuning
Resolución de entrada	224×224	160×160
Capas entrenadas	capa lineal	últimas etapas + cabeza
Optimizador	AdamW	AdamW
Learning rate ^a	3×10^{-3}	$10^{-3} / 3 \times 10^{-4}$
Weight decay	10^{-3}	10^{-4}
Scheduler	coseno	coseno
Batch / épocas	256 / 60	32 / 8
Pérdida	CE y CE ponderada	CE
Selección del modelo	máximo macro-F1 en validación	

^aEn fine-tuning: cabeza / backbone.

referencia sin optimización para dispositivos móviles, ResNet18. Como el entrenamiento se realizó íntegramente en CPU, seguimos una estrategia en dos etapas:

1. **Linear probe:** con el backbone congelado, extraemos una única vez los embeddings de todas las imágenes a 224×224 y entrenamos sobre ellos una capa lineal. Esta etapa, de pocos segundos por modelo, mide la calidad de las representaciones de ImageNet para este dominio y permite comparar las cuatro arquitecturas a bajo costo. También evaluamos una entropía cruzada ponderada por la frecuencia inversa de cada clase.
2. **Fine-tuning parcial:** para las dos arquitecturas con mayor macro-F1 en validación en la etapa anterior (EfficientNet-B0 y MobileNetV3-Small, esta última además la de menor costo), reemplazamos el clasificador y reentrenamos las últimas etapas del backbone (6 bloques en MobileNetV3-Small y 3 en EfficientNet-B0, con 1,39M y 3,17M parámetros entrenables, respectivamente). Las BatchNorm de las etapas congeladas se mantienen en modo evaluación para no alterar sus estadísticas. Cada arquitectura se entrena con y sin data augmentation, en un diseño 2×2 en el que todo lo demás (semilla, partición, resolución, optimizador y número de épocas) permanece fijo.

II-E. Protocolo de entrenamiento y métricas

La Tabla I resume los hiperparámetros de ambas etapas. Para reducir el costo en CPU, el fine-tuning se realiza a 160×160 píxeles. En las dos etapas, la mejor época se elige por macro-F1 en validación, y el conjunto de test se evalúa una única vez con el modelo seleccionado. Reportamos accuracy, balanced accuracy y macro-F1, además del F1 por clase y la matriz de confusión para el análisis de errores. Como métricas de costo registramos el tiempo de entrenamiento, el número de parámetros y la latencia de inferencia en CPU.

II-F. Explicabilidad con Grad-CAM

Para auditar en qué regiones de la imagen se basa el modelo final aplicamos Grad-CAM [10] sobre la última capa convolucional del backbone (un mapa de 5×5 a la resolución de entrada), calculado para la clase predicha. Además del análisis visual, cuantificamos la atención del modelo sobre

todo el conjunto de test. Para cada imagen segmentamos la hoja aprovechando el fondo uniforme: estimamos el color del fondo en el borde de la imagen y aplicamos un umbral de Otsu sobre la distancia cromática a ese color en el plano (a^*, b^*) de CIELAB, seguido de limpieza morfológica y relleno de huecos. Usar solo la cromaticidad evita que las sombras se confundan con la hoja y conserva las lesiones oscuras. Con la máscara M resultante y el mapa Grad-CAM normalizado L calculamos la fracción de la activación que recae sobre la hoja:

$$E_{\text{hoja}} = \frac{\sum_{i,j} L_{ij} M_{ij}}{\sum_{i,j} L_{ij}}, \quad (1)$$

Como un mapa uniforme obtendría un valor igual al área relativa de la hoja, también reportamos el cociente entre E_{hoja} y esa área (mayor que 1 si la atención se concentra en la hoja más de lo esperable por azar). Por último, aplicamos el *pointing game*, que mide el porcentaje de imágenes cuyo máximo de activación cae dentro de la hoja. Estas métricas permiten detectar si el modelo explota el fondo, un sesgo conocido de PlantVillage [4], en lugar de los síntomas.

II-G. Evaluación de robustez y con datos externos

Para estimar el comportamiento fuera de las condiciones de captura de PlantVillage realizamos dos evaluaciones complementarias, que no se usan para seleccionar ningún modelo. Primero, aplicamos al conjunto de test cinco perturbaciones fijadas de antemano: oscurecimiento y aclarado (factor de brillo 0,65 y 1,35), rotación de 25° seguida de un recorte central, acercamiento del 20 % (recorte central) y desenfoque gaussiano (núcleo de 5×5 , $\sigma = 1,5$). Segundo, evaluamos sobre imágenes de PlantDoc [5], tomadas en condiciones reales (fondos complejos, varias hojas por imagen, iluminación natural). Elegimos las seis clases de PlantDoc con un equivalente directo en nuestro conjunto (tizón temprano y tardío de la papa; mancha bacteriana, tizón temprano, tizón tardío y septoriosis del tomate) y tomamos al azar cinco imágenes de cada una de su partición de test (30 imágenes). Los modelos conservan sus 15 salidas, por lo que predecir cualquier otra clase cuenta como error.

III. RESULTADOS EXPERIMENTALES Y ANÁLISIS

III-A. Comparación de backbones (linear probe)

La Tabla II resume el desempeño de una capa lineal entrenada sobre los embeddings congelados de cada backbone. Sin modificar ningún peso preentrenado, todas las arquitecturas superan el 94 % de macro-F1 en test, lo que confirma que las representaciones de ImageNet transfieren bien a este dominio. Las arquitecturas diseñadas para dispositivos móviles superan a ResNet18 (macro-F1 de 0,959–0,961 contra 0,942) a pesar de tener entre 2,8 y 12 veces menos parámetros. Entre ellas, las diferencias en test son de a lo sumo 0,003, del orden de la variabilidad entre validación y test: EfficientNet-B0 obtiene el mayor macro-F1 en validación y MobileNetV3-Small, uno prácticamente igual con una extracción 3,2 veces más rápida.




Figura 2. Grad-CAM del modelo EfficientNet-B0 con augmentation sobre imágenes de test. Las tres columnas de la izquierda muestran aciertos típicos (imagen con la mediana de E_{hoja} dentro de su clase) y las tres de la derecha, los errores con mayor confianza. El contorno blanco indica la máscara de la hoja usada para calcular E_{hoja} .

Tabla II
LINEAR PROBE SOBRE BACKBONES CONGELADOS (ENTROPÍA CRUZADA SIN PONDERAR)

Backbone	Parám.	Extracción	Macro-F1		Bal. acc.
			val	test	
	(M)	(img/s)			
MobileNetV3-Small	0,9	126,0	0,971	0,959	0,961
MobileNetV3-Large	3,0	59,5	0,967	0,960	0,957
EfficientNet-B0	4,0	39,9	0,973	0,961	0,963
ResNet18	11,2	39,1	0,942	0,942	0,941

La entropía cruzada ponderada no mostró un beneficio consistente: modificó el macro-F1 en test entre $-0,006$ y $+0,001$ según el modelo, por lo que no la utilizamos en el fine-tuning.

III-B. Fine-tuning con y sin data augmentation

El fine-tuning parcial mejora de forma sustancial el linear probe (Tabla III). Con la mejor variante de cada arquitectura, el macro-F1 en test pasa de $0,959$ a $0,987$ en MobileNetV3-Small y de $0,961$ a $0,993$ en EfficientNet-B0, lo que equivale a reducir la fracción de error ($1 - \text{macro-F1}$) un 69 % y un 81 %, respectivamente. Adaptar las últimas etapas del backbone resulta, entonces, mucho más determinante que la elección de la arquitectura en la etapa de linear probe. EfficientNet-B0 supera a MobileNetV3-Small en todas las métricas, con aproximadamente la mitad de errores, pero cada época de entrenamiento le demanda unas 3,3 veces más tiempo (≈ 330 s contra ≈ 100 s en nuestra CPU).

El data augmentation no mejoró el desempeño en el test de PlantVillage: las diferencias entre las corridas con y sin augmentation son de a lo sumo $0,0024$ en macro-F1 y van en sentidos opuestos según la arquitectura, un margen que no consideramos significativo con una sola semilla. Sí se observa

Tabla III
FINE-TUNING PARCIAL A 160×160 (8 ÉPOCAS, CPU)

Modelo	Aug.	Parám. entren. (M)	F1 val	F1 test	Errores test
MobileNetV3-S	no	1,39	0,992	0,987	25
MobileNetV3-S	sí	1,39	0,985	0,985	33
EfficientNet-B0	no	3,17	0,994	0,990	19
EfficientNet-B0	sí	3,17	0,994	0,993	17

su efecto regularizador: sin augmentation, EfficientNet-B0 termina con una pérdida de entrenamiento de $0,004$ frente a $0,019$ en validación (memoriza el conjunto de entrenamiento), mientras que con augmentation la pérdida de entrenamiento ($0,033$) queda por encima de la de validación ($0,019$). En la misma línea, las corridas sin augmentation alcanzan su mejor macro-F1 de validación en las épocas 5 y 6, mientras que las corridas con augmentation lo hacen en la última época, por lo que podrían beneficiarse de un entrenamiento más largo. Como el test proviene de la misma distribución que el entrenamiento, es esperable que el beneficio del augmentation aparezca recién ante condiciones de captura distintas (Secciones III-E y III-F). Por eso elegimos como modelo final a EfficientNet-B0 con augmentation: en validación empató con la versión sin augmentation ($0,9938$ contra $0,9942$) y, como se muestra más adelante, es mucho más robusto.

III-C. Análisis por clase y de errores

Con el modelo final, todas las clases superan un F1 de $0,975$. Las más bajas son papa sana ($0,976$) y tizón temprano del tomate ($0,979$). Papa sana es la clase con menor F1 en las cuatro corridas, lo que es coherente con que sea la clase minoritaria (21 imágenes de test). De los 17 errores, 16 ocurren




Figura 3. Distribución de E_{hoja} (fracción de la activación Grad-CAM sobre la hoja) en las 2949 imágenes de test. Los triángulos marcan los 17 errores; la línea punteada, el área media que ocupa la hoja.

entre clases de una misma especie; la excepción confunde una papa sana con un pimiento sano. Solo dos errores confunden una hoja sana con una enferma (pimiento sano clasificado como mancha bacteriana). Las confusiones más frecuentes se dan entre enfermedades del tomate con síntomas visualmente parecidos: mancha diana contra ácaro araña y tizón tardío contra tizón temprano (4 errores cada par). Estos mismos pares ya aparecían como los principales errores del linear probe, lo que sugiere una ambigüedad propia de los síntomas más que una limitación de un modelo en particular.

III-D. Explicabilidad (Grad-CAM)

En el conjunto de test completo, el 65,7 % de la activación Grad-CAM del modelo final recae sobre la hoja, que ocupa en promedio el 40,2 % de la imagen: la atención está 1,71 veces más concentrada en la hoja de lo que se esperaría por azar. Además, el máximo de activación cae dentro de la hoja en el 96,5 % de las imágenes (Fig. 3). Los aciertos de la Fig. 2 muestran que el modelo se enfoca en las lesiones necróticas y en las zonas cloróticas.

Los errores no se explican por una atención desviada hacia el fondo: su E_{hoja} medio (0,58) y su *pointing game* (94 %) son apenas menores que los de los aciertos (0,66 y 97 %). Es decir, el modelo mira la hoja pero interpreta mal síntomas ambiguos. La excepción es una hoja de TYLCV de tamaño muy reducido, en la que la activación se extiende sobre el fondo (Fig. 2, quinta columna). Las clases con menor E_{hoja} son el virus del mosaico (0,50) y el tizón tardío del tomate (0,52), cuyas hojas suelen estar enrolladas o deformadas y ocupan menos superficie de la imagen. Parte de la activación fuera de la hoja se debe a la baja resolución del mapa (5×5), que al interpolarse se extiende sobre los bordes. Aun así, que cerca de un tercio de la activación caiga fuera de la hoja indica que el fondo no es completamente irrelevante para el modelo, en línea con el sesgo descrito en [4].

III-E. Robustez ante perturbaciones

La Tabla IV muestra que el data augmentation, que no cambiaba el desempeño en el test original, es el factor que determina la robustez. Sin augmentation, ambos modelos toleran bien los cambios de iluminación (caídas de macro-F1

Tabla IV
MACRO-F1 EN TEST BAJO PERTURBACIONES

Perturbación	MobileNetV3-S		EfficientNet-B0	
	sin aug.	con aug.	sin aug.	con aug.
Ninguna (original)	0,987	0,985	0,990	0,993
Oscurecimiento	0,969	0,983	0,988	0,993
Aclarado	0,975	0,985	0,989	0,990
Rotación 25°	0,865	0,977	0,904	0,990
Acercamiento 20 %	0,952	0,991	0,976	0,991
Desenfoque	0,786	0,974	0,756	0,980
Promedio perturbado	0,909	0,982	0,922	0,989

de a lo sumo 0,02), pero se degradan ante la rotación (0,12 en MobileNetV3-Small y 0,09 en EfficientNet-B0) y, sobre todo, ante el desenfoque (0,20 y 0,23). Con augmentation, la mayor caída es de 0,013 y el macro-F1 promedio sobre las imágenes perturbadas sube de 0,909 a 0,982 en MobileNetV3-Small y de 0,922 a 0,989 en EfficientNet-B0. La mayor capacidad de EfficientNet-B0 no lo protege por sí sola: sin augmentation, es incluso más sensible al desenfoque que MobileNetV3-Small. Cabe aclarar que las cinco perturbaciones están contenidas en el pipeline de augmentation (Sección II-C), por lo que este resultado muestra la invariancia adquirida frente a transformaciones vistas en el entrenamiento, y no una generalización a condiciones nuevas.

III-F. Evaluación con datos externos

Sobre las 30 imágenes de PlantDoc, ambos modelos EfficientNet-B0 aciertan solo 11 (36,7 %; intervalo de confianza del 95 % de Wilson: 22–55 %), frente al 99,4 % del test de PlantVillage. El macro-F1 sobre las seis clases es de 0,39 sin augmentation y de 0,31 con augmentation, de modo que el augmentation, que sí aportaba robustez ante perturbaciones sintéticas, no reduce la brecha de dominio. Los errores muestran que el modelo pierde referencias básicas: con augmentation, 20 de las 30 predicciones se concentran en tizón temprano o tardío del tomate, y 9 de los 19 errores asignan la hoja a otra especie, en tres casos como pimiento sano. Además, 5 errores tienen una confianza mayor al 90 %, por lo que la confianza del modelo no alcanza para detectar que una imagen está fuera de su dominio. Este resultado, aunque basado en una muestra pequeña, coincide con la caída reportada en [3] y con el desempeño en el campo de [7]: un accuracy cercano al 100 % en PlantVillage no se traslada a fotografías tomadas en condiciones reales.

III-G. Costo computacional

La Tabla V compara el costo de inferencia de los dos modelos ajustados en una CPU de notebook (Intel Core i7-1355U), con entrada de 160×160 . Ambos permiten clasificar en tiempo real sin GPU: EfficientNet-B0 procesa una imagen en 17,5 ms y MobileNetV3-Small en 7,1 ms, con un modelo 2,6 veces más liviano (5,9 MB). Si se prioriza el desempeño, EfficientNet-B0 es la mejor opción para el prototipo. MobileNetV3-Small, que comete casi el doble de errores pero es 2,5 veces más

Tabla V
COSTO DE INFERENCIA EN CPU (160 × 160, FP32)

Modelo	Parám. (M)	Tamaño (MB)	Latencia bs=1 media (p95) [ms]	Throughput bs=32 [img/s]
MobileNetV3-Small	1,53	5,9	7,1 (9,1)	931
EfficientNet-B0	4,03	15,5	17,5 (20,5)	151

rápido y con augmentation resulta igualmente robusto, es una alternativa adecuada para dispositivos más limitados, como un teléfono de gama baja.

IV. CONCLUSIONES

En este trabajo desarrollamos y evaluamos un prototipo de clasificación de enfermedades foliares en pimiento, papa y tomate a partir de modelos livianos preentrenados en ImageNet, entrenados íntegramente en CPU. Las principales conclusiones son las siguientes:

1. **El fine-tuning parcial es más determinante que la elección del backbone.** Las representaciones de ImageNet ya alcanzan un macro-F1 de 0,96 con un linear probe, con diferencias mínimas entre arquitecturas móviles. Reentrenar solo las últimas etapas lleva el macro-F1 a 0,987–0,993 y reduce la fracción de error entre un 69 y un 81 %, con un costo de entrenamiento compatible con una CPU de notebook.
2. **Las arquitecturas móviles ofrecen el mejor compromiso.** Superan a ResNet18 con muchos menos parámetros y permiten inferencia en tiempo real sin GPU. EfficientNet-B0 obtiene el mejor desempeño (17 errores en 2 949 imágenes de test, 17,5 ms por imagen), mientras que MobileNetV3-Small es 2,5 veces más rápido a cambio de casi el doble de errores, lo que lo hace adecuado para dispositivos más limitados.
3. **El valor del data augmentation no se ve en el test de la misma distribución.** Sin cambiar el macro-F1 en el test original, el augmentation reduce la caída ante perturbaciones de hasta 0,23 a menos de 0,015. Elegir el modelo solo por su desempeño en el test habría descartado la variante más robusta.
4. **El modelo se basa principalmente en la hoja, pero no ignora el fondo.** Según Grad-CAM, el 65,7 % de la activación recae sobre la hoja (1,7 veces lo esperable por azar) y los errores se deben a síntomas ambiguos entre enfermedades de una misma especie más que a una atención desviada. Aun así, cerca de un tercio de la activación cae fuera de la hoja, lo que deja abierta la posibilidad de que el modelo aproveche regularidades del fondo de PlantVillage.
5. **Un desempeño cercano al 100 % en PlantVillage no garantiza utilidad en el campo.** Sobre imágenes reales de PlantDoc, el accuracy cae al 36,7 % y el modelo comete errores con alta confianza, incluso confundiendo la especie. El augmentation con transformaciones geométricas y de color no alcanza para cubrir esa brecha de

dominio, por lo que el prototipo, en su estado actual, no debería usarse para diagnosticar en condiciones reales.

Entre las limitaciones del estudio se encuentran el uso de una única semilla, la muestra externa reducida (30 imágenes) y la fuga de datos que el agrupamiento por dHash no evita entre fotografías rotadas de una misma hoja. Como trabajo futuro proponemos incorporar imágenes de campo al entrenamiento o reemplazar el fondo de las hojas de PlantVillage, agregar un mecanismo de detección de imágenes fuera de distribución que permita al sistema abstenerse ante casos dudosos, repetir los experimentos con varias semillas y un conjunto externo más amplio, y evaluar el modelo cuantizado directamente en un teléfono móvil.

REFERENCIAS

- [1] S. Savary, L. Willocquet, S. J. Pethybridge, P. Esker, N. McRoberts, and A. Nelson, "The global burden of pathogens and pests on major food crops," *Nature Ecology & Evolution*, vol. 3, no. 3, pp. 430–439, 2019.
- [2] D. P. Hughes and M. Salathé, "An open access repository of images on plant health to enable the development of mobile disease diagnostics," arXiv:1511.08060, 2015. [Online]. Available: <https://arxiv.org/abs/1511.08060>
- [3] S. P. Mohanty, D. P. Hughes, and M. Salathé, "Using deep learning for image-based plant disease detection," *Frontiers in Plant Science*, vol. 7, p. 1419, 2016.
- [4] M. A. Noyan, "Uncovering bias in the PlantVillage dataset," arXiv:2206.04374, 2022. [Online]. Available: <https://arxiv.org/abs/2206.04374>
- [5] D. Singh, N. Jain, P. Jain, P. Kayal, S. Kumawat, and N. Batra, "PlantDoc: A dataset for visual plant disease detection," in *Proc. 7th ACM IKDD CoDS and 25th COMAD*, 2020, pp. 249–253.
- [6] A. Ramcharan, P. McCloskey, K. Baranowski, N. Mbilinyi, L. Mrisho, M. Ndalawha, J. Legg, and D. P. Hughes, "A mobile-based deep learning model for cassava disease diagnosis," *Frontiers in Plant Science*, vol. 10, p. 272, 2019.
- [7] L. M. Mrisho, N. A. Mbilinyi, M. Ndalawha et al., "Accuracy of a smartphone-based object detection model, PlantVillage Nuru, in identifying the foliar symptoms of the viral diseases of cassava-CMD and CBSD," *Frontiers in Plant Science*, vol. 11, p. 590889, 2020.
- [8] A. Howard, M. Sandler, G. Chu, L.-C. Chen, B. Chen, M. Tan, W. Wang, Y. Zhu, R. Pang, V. Vasudevan, Q. V. Le, and H. Adam, "Searching for MobileNetV3," in *Proc. IEEE/CVF Int. Conf. Computer Vision (ICCV)*, 2019, pp. 1314–1324.
- [9] M. Tan and Q. V. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in *Proc. 36th Int. Conf. Machine Learning (ICML)*, ser. PMLR, vol. 97, 2019, pp. 6105–6114.
- [10] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, "Grad-CAM: Visual explanations from deep networks via gradient-based localization," in *Proc. IEEE Int. Conf. Computer Vision (ICCV)*, 2017, pp. 618–626.